



# 图神经网络的并行化

报告人：王云攀

时间：2019.10.31


- 一、图神经网络概述
- 二、1stChebNet算法<sup>[1]</sup>介绍及实现
- 三、下一步工作

1. Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.

# 一、图神经网络概述

## 1. 什么是图神经网络?


- 输入
  - 图的结构和节点的内容信息
- 输出
  - Node-level, 关于节点的回归和分类任务, 最后一层为softmax函数或者感知机
  - Edge-level, 对边的分类或者预测任务, 一个额外的函数用于连接边的表示
  - Graph-level, 图的分类任务, 最后一层为pooling层
- 学习类型
  - 半监督学习, Node-level classification, 先学习有标记数据, 再对未标记数据进行分类
  - 监督学习, Graph-level classification, 给出图数据集, 预测整个图的类别标签。
  - 无监督学习: Graph-embedding, 学习图的表示
- 每层的基本操作
  - 聚集邻居节点的信息产生新的表示
  - 每个节点的表示再表示




## 1. 什么是图神经网络?

- GNN vs RNN<sup>[1]</sup>

Graph  
Neural  
Network



Recurrent  
Neural  
Network



[1]. 图片来源于[https://www.cnblogs.com/SivilTaram/p/graph\\_neural\\_network\\_1.html](https://www.cnblogs.com/SivilTaram/p/graph_neural_network_1.html)



## 2. 为什么使用图神经网络？

- 背景<sup>[1]</sup>
  - 深度学习在图像、视频和文本应用广泛，从数据中挖掘出复杂的模式的表达能力已得到公认。
  - 另一方面，Graph在现实世界中无处不在，表示对象以及关系，例如社交网络、电子商务网络、生物学网络和交通网络。
  - 图具有复杂的结构，包含丰富的基础价值。
- 特点<sup>[2]</sup>
  - Each graph has a variable size of unordered nodes
  - Each node in a graph has a different number of neighbors

[1]. Zhang Z, Cui P, Zhu W. Deep learning on graphs: A survey[J]. arXiv preprint arXiv:1812.04202, 2018.

[2]. Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019.

## 3. 图神经网络的历史

- 萌芽期 (2005~2009)
  - Gori et al.(2005)<sup>[1]</sup>, 基于不动点理论, 考虑节点和边的特征, 学习节点的表示, 想法是通过结点的信息传播使整张图达到收敛, 在其基础上进行预测。
    - 问题: 试图寻找确定解, 达到收敛使得迭代长度无法确定, 采用AP算法进行反向传播, 需要对函数进行特别设计, 满足收敛性。同时, 计算开销巨大。
  - Scarselli et al.(2008)<sup>[2]</sup>, Micheli (2009)<sup>[3]</sup>, 在以上的基础上进行改进, 但仍然基于迭代达到稳定状态的想法来做, 没有解决计算开销的问题。

[1]. Gori M, Monfardini G, Scarselli F. A new model for learning in graph domains[C]//Proceedings. 2005 IEEE International Joint Conference on Neural Networks, 2005. IEEE, 2005, 2: 729-734.

[2]. Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2008, 20(1): 61-80.

[3]. Micheli A. Neural network for graphs: A contextual constructive approach[J]. IEEE Transactions on Neural Networks, 2009, 20(3): 498-511.



## 3. 图神经网络的历史

- 蓬勃发展期（2013至今）
  - Spectral CNN, ICLR 2014<sup>[1]</sup>, 首次将卷积操作应用到图神经网络中, 基于频域的方法进行考虑
  - Graph Sequence Neural Network, ICLR 2016<sup>[2]</sup>, 将GRU引入, 将GNN固定在了T步, 并且可以来预测序列任务
  - Graph Attention Network, ICLR 2017<sup>[3]</sup> 开始考虑了邻居节点的权重
  - Inductive representation learning on large graphs, NIPS 2017<sup>[4]</sup> 提出了GraphSage, 关于图神经网络的一种框架

[1]. Bruna J, Zaremba W, Szlam A, et al. Spectral networks and locally connected networks on graphs[J]. arXiv preprint arXiv:1312.6203, 2013.

[2]. Li Y, Tarlow D, Brockschmidt M, et al. Gated graph sequence neural networks[J]. arXiv preprint arXiv:1511.05493, 2015.

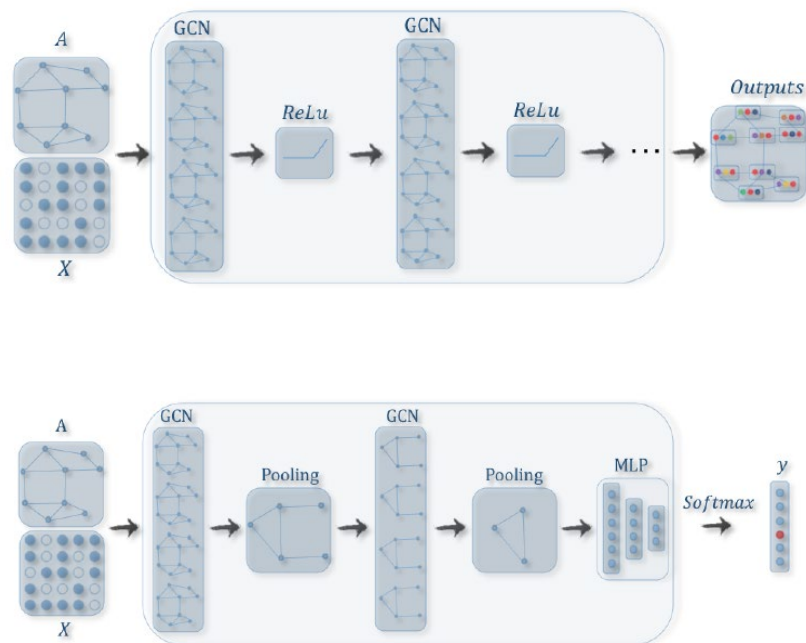
[3]. Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[J]. arXiv preprint arXiv:1710.10903, 2017.

[4]. Hamilton W, Ying Z, Leskovec J. Inductive representation learning on large graphs[C]//Advances in Neural Information Processing Systems. 2017: 1024-1034.



## 4. 图神经网络的分类<sup>[1]</sup>

- **Graph Convolution Networks**: 模拟传统数据集上的卷积操作，通过自身和邻居的特征来学习节点的表示
  - Spectral Based 方法：基于频域的方法
  - Spatial Based 方法：基于空间的方法



[1]. Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019.

## 4. 图神经网络的分类<sup>[1]</sup>


- Graph Convolution Networks

| Category       | Approach                 | Inputs<br>(allow edge features?) | Outputs     | Output Mechanisms   |                            |
|----------------|--------------------------|----------------------------------|-------------|---------------------|----------------------------|
|                |                          |                                  |             | Intermediate        | Final                      |
| Spectral Based | Spectral CNN (2014) [21] | ✗                                | Graph-level | cluster+max pooling | softmax function           |
|                | ChebNet (2016) [12]      | ✗                                | Graph-level | efficient pooling   | mlp layer+softmax function |
|                | 1stChebNet (2017) [14]   | ✗                                | Node-level  | activation function | softmax function           |
|                | AGCN (2018) [23]         | ✗                                | Graph-level | max pooling         | sum pooling                |
| Spatial Based  | GNN (2009) [18]          | ✓                                | Node-level  | -                   | mlp layer+softmax function |
|                |                          |                                  | Graph-level | -                   | add a dummy super node     |
|                | GGNNs (2015) [19]        | ✗                                | Node-level  | -                   | mlp layer/softmax function |
|                |                          |                                  | Graph-level | -                   | sum pooling                |
|                | SSE (2018) [20]          | ✗                                | Node-level  | -                   | softmax function           |
|                | MPNN (2017) [13]         | ✓                                | Node-level  | -                   | softmax function           |
|                |                          |                                  | Graph-level | -                   | sum pooling                |
|                | GraphSage (2017) [25]    | ✗                                | Node-level  | activation function | softmax function           |
|                | DCNN (2016) [47]         | ✓                                | Node-level  | activation function | softmax function           |
|                |                          |                                  | Graph-level | -                   | mean pooling               |
|                | PATCHY-SAN (2016) [27]   | ✓                                | Graph-level | -                   | mlp layer+softmax function |
|                | LGCN (2018) [28]         | ✗                                | Node-level  | skip connections    | mlp layer+softmax function |


[1]. Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019.

## 4. 图神经网络的分类<sup>[1]</sup>

- **Graph Attention Networks**: 跟GCNs类似, 试图融合邻居节点, 随机行走 (Random Walk), 候选模型来寻找函数。采用了注意力机制, 会分配更大的注意力权重给更重要的节点、步行或者模型。



(a) Graph Convolution Networks [14] explicitly assign a non-parametric weight  $a_{ij} = \frac{1}{\sqrt{\deg(v_i) \deg(v_j)}}$  to the neighbor  $v_j$  of  $v_i$  during the aggregation process.




(b) Graph Attention Networks [15] implicitly capture the weight  $a_{ij}$  via an end-to-end neural network architecture, so that more important nodes receive larger weights.

[1]. Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019.

## 4. 图神经网络的分类<sup>[1]</sup>


- **Graph Auto-encoders**: 无监督的学习框架，旨在通过编码器学习节点低维表示，并且能够通过解码器重构图形。它是一种流行的学习图形嵌入（Graph Embedding）的方法。
  - 在化学图中，原子被视为节点，化学键被视为边缘。任务是发现新的可合成分子具有某些化学和物理性质。



[1]. Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019.

## 4. 图神经网络的分类<sup>[1]</sup>


- **Graph Generative Networks:** 旨在生成合理图形数据的结构。从图的经验分布上产生图本身是个很难的问题，通常的方法是通过探索将产生的因素交替形成节点和边，进行生成式对抗训练。最广阔的应用领域是化合物的合成



[1]. Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019.

## 4. 图神经网络的分类<sup>[1]</sup>

- **Graph Spatial-temporal Networks:**  
旨在从时空图中学习看不见的模式，在交通流量预测和人类活动预测应用越来越广泛。图是考虑空间依赖性和时间依赖性。许多当前的方法采用GCN和一些RNN或CNN来对时空依赖性建模



[1]. Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019.

## 4. 图神经网络的分类<sup>[1]</sup>

- 其他

| Category                        | Approaches                  | Inputs |   |   | Outputs                                 | Tasks                           | GCN Based |
|---------------------------------|-----------------------------|--------|---|---|---|---------------------------------|-----------|
|                                 |                             | A      | D | S |   |                                 |           |
| Graph Attention Networks        | GAT (2017) [15]             | ✓      | ✓ | ✗ | node labels                             | node classification             | ✓         |
|                                 | GAAN (2018) [29]            | ✓      | ✓ | ✗ | node labels                             | node classification             | ✓         |
|                                 | GAM (2018) [60]             | ✓      | ✓ | ✗ | graph labels                            | graph classification            | ✗         |
|                                 | Attention Walks (2018) [61] | ✗      | ✗ | ✗ | node embedding                          | network embedding               | ✗         |
| Graph Auto-encoder              | GAE (2016) [62]             | ✓      | ✗ | ✗ | reconstructed adjacency matrix          | network embedding               | ✓         |
|                                 | ARGA (2018) [64]            | ✓      | ✗ | ✗ | reconstructed adjacency matrix          | network embedding               | ✓         |
|                                 | NetRA (2018) [65]           | ✗      | ✗ | ✗ | reconstructed sequences of random walks | network embedding               | ✗         |
|                                 | DNGR (2016) [42]            | ✗      | ✗ | ✗ | reconstructed PPMI matrix               | network embedding               | ✗         |
|                                 | SDNE (2016) [43]            | ✗      | ✓ | ✗ | reconstructed adjacency matrix          | network embedding               | ✗         |
|                                 | DNRE (2018) [66]            | ✓      | ✗ | ✗ | reconstructed node embedding            | network embedding               | ✗         |
| Graph Generative Networks       | MolGAN (2018) [69]          | ✓      | ✗ | ✗ | new graphs                              | graph generation                | ✓         |
|                                 | DGMG (2018) [68]            | ✗      | ✗ | ✗ | new graphs                              | graph generation                | ✓         |
|                                 | GraphRNN (2018) [67]        | ✗      | ✗ | ✗ | new graphs                              | graph generation                | ✗         |
|                                 | NetGAN (2018) [70]          | ✗      | ✗ | ✗ | new graphs                              | graph generation                | ✗         |
| Graph Spatial-Temporal Networks | DCRNN (2018) [73]           | ✗      | ✗ | ✓ | node value vectors                      | spatial-temporal forecasting    | ✓         |
|                                 | CNN-GCN (2017) [74]         | ✗      | ✗ | ✓ | node value vectors                      | spatial-temporal forecasting    | ✓         |
|                                 | ST-GCN (2018) [75]          | ✗      | ✗ | ✓ | graph labels                            | spatial-temporal classification | ✓         |
|                                 | Structural RNN (2016) [76]  | ✗      | ✗ | ✓ | node labels/value vectors               | spatial-temporal forecasting    | ✗         |

[1]. Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019.



## 5. 图神经网络未来的方向<sup>[1]</sup>

- Go Deep: 根据<sup>[2]</sup>, 图形卷积的影响推动相邻节点的表示彼此更靠近, 因此, 理论上, 随着无限次的卷积, 所有节点的表示将收敛到单个点。这就提出了一个问题, 即深入学习图形结构化数据是否仍是一个不错的策略
- Receptive Field: 观察一个节点时, 考虑更远的邻居;
- Scalability: 将图扩展到更大规模的图上, 现有办法: 快采样和子图训练
- Dynamics and Heterogeneity: 现有的图都是静态的同质的图, 考虑图的结构变化, 节点和边的来源不同的情况

[1]. Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019.

[2]. Q. Li, Z. Han, and X.-M. Wu, "Deeper insights into graph convolutional networks for semi-supervised learning," in Proceedings of the AAAI Conference on Artificial Intelligence, 2018.




## 二、1stChebNet算法介绍及其实现

## 1. 算法介绍

- 该论文属于Graph Convolution Network中Spectral Based的方法，实验结果只使用了三层网络就取得了很好的实验结果。
- 所属类型：
  - 半监督学习
  - inductive learning
  - Node-level, 学习节点的类别
- 该三层网络结构也可以很容易的扩展到多层 (n+1层) 网络结构，表达式如下所示：

$$\mathcal{L} = - \sum_{l \in \mathcal{Y}_L} \sum_{f=1}^F Y_{lf} \ln Z_{lf},$$

$$Z = f(X, A) = \text{softmax}(\hat{A} \text{ReLU}(\hat{A} X W^{(0)}) W^{(1)}).$$



(a) Graph Convolutional Network

$$Z = f(X, A) = \text{softmax}(\hat{A} \text{ReLU}(\hat{A} \text{ReLU}(\dots \text{ReLU}(\hat{A} X W^{(0)}) \dots) W^{(n-1)}) W^{(n)})$$

### 1. 算法介绍

- 关键矩阵

1.  $\tilde{A} = A + I_N$

2.  $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$

3.  $\hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$


$$a_{ij} = \frac{1}{\sqrt{d_i} \sqrt{d_j}}$$

- 解释

- A是邻接矩阵（对称，要求无向图）
- 第1步，添加自身的权重
- 第2步，统计每个节点的度数
- 第3步，考虑边

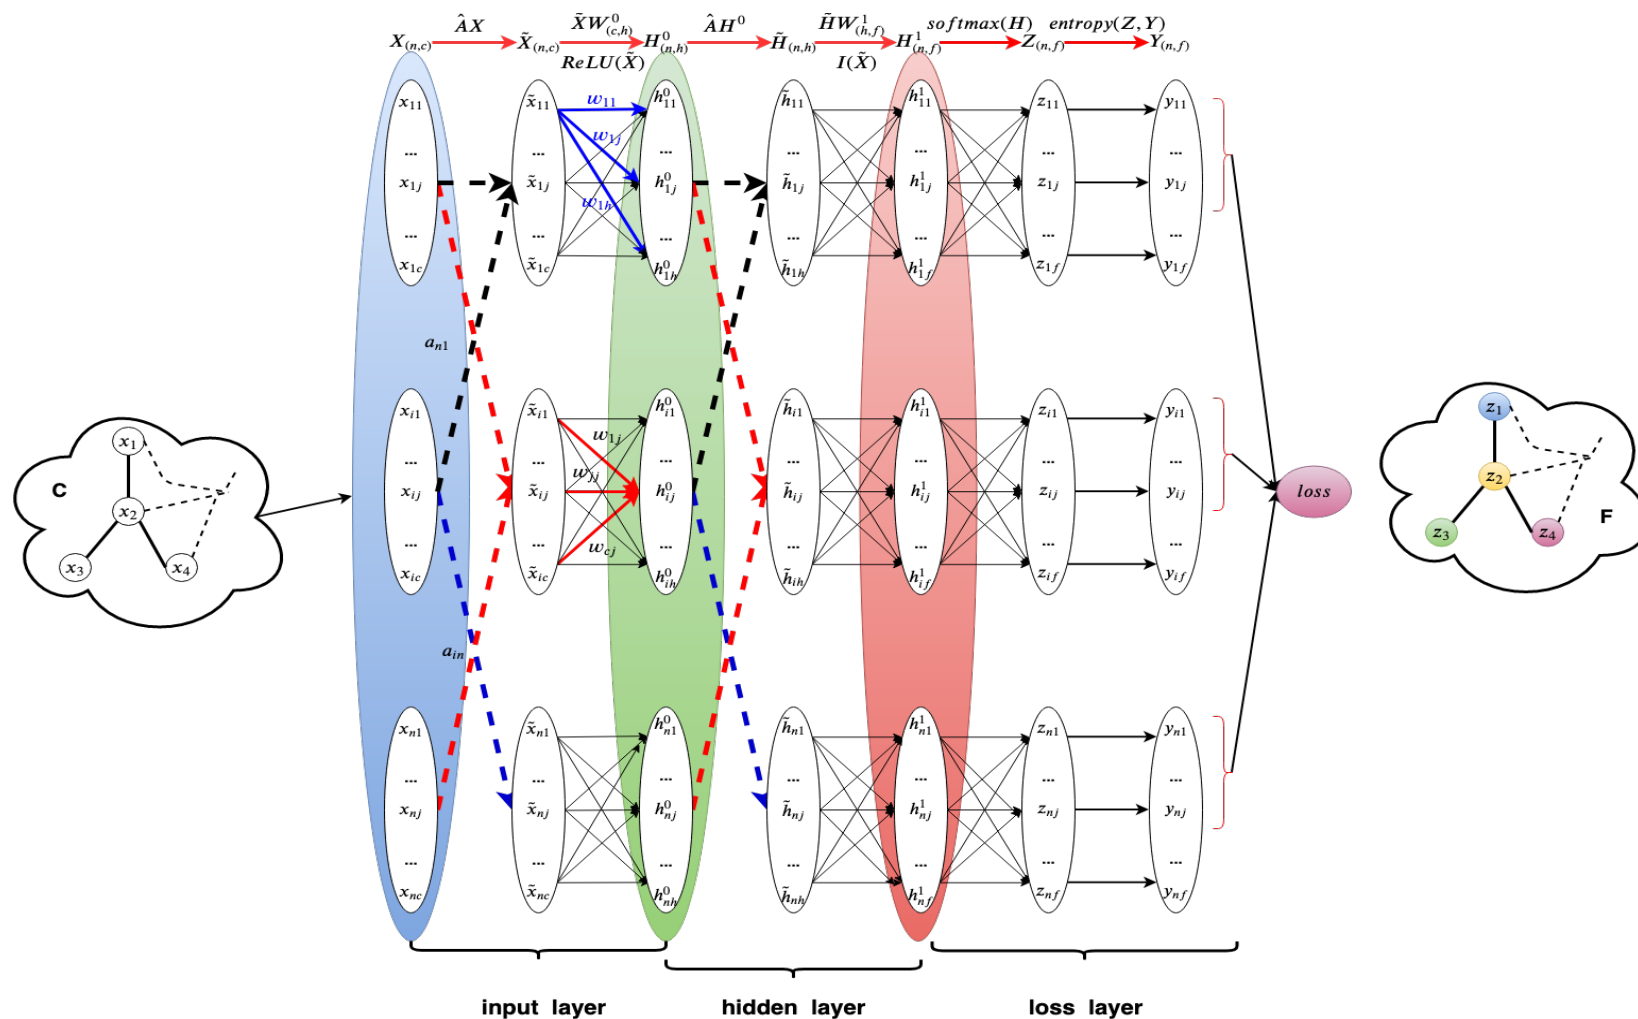
- 实际意义

- 减少度数多的节点对自己的影响




## 二、1stChebNet算法介绍及实现

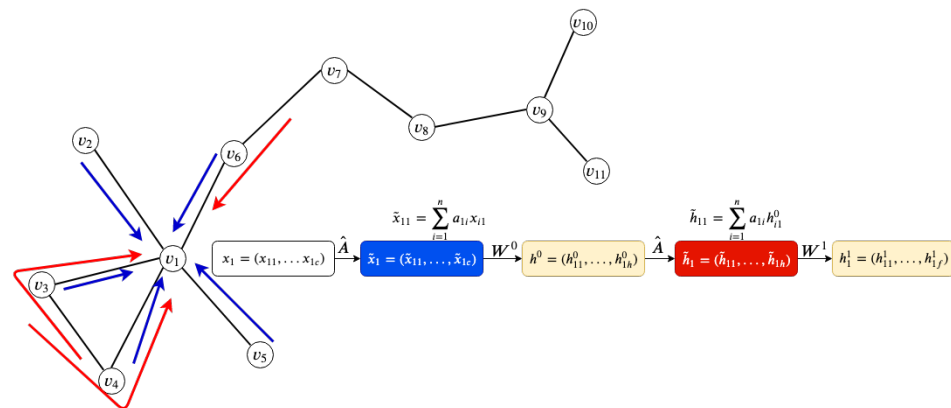
### 2. 算法实现——前向传播(整个过程)



## 2. 算法实现——前向传播(图的角度)




- 从实际图的角度看，实际上几层网络结构，就是当前节点收集几跳邻居节点的信息



# 二、1stChebNet算法介绍及实现

## 2. 算法实现——前向传播（矩阵角度）



input  
layer

hidden  
layer

loss  
layer

$$\tilde{X}_{(n,c)} = \hat{A}_{(n,n)} X_{(n,c)}$$

$$H_{(n,h)}^0 = \text{ReLU}(\tilde{X}_{(n,c)} W_{(c,h)}^0)$$

$$\tilde{H}_{(n,h)} = \hat{A}_{(n,n)} H_{(n,h)}^0$$

$$H_{(n,f)}^1 = \tilde{H}_{(n,h)} W_{(h,f)}^1$$

$$Z_{(n,f)} = \text{softmax}(H_{(n,f)}^1)$$

$$loss = \text{entropy}(Z_{(n,f)}, Y_{(n,f)})$$

## 2. 算法实现——反向传播（梯度下降，矩阵角度）

- 对于反向传播，正向传播转换为了矩阵相乘的操作，所以试图从矩阵的角度概括反向传播，经过学习总结如下：

- 链式法则：连接各个layer
- 标量对矩阵的求导 loss layer
- 矩阵对矩阵的求导 hidden layer和 input layer

- 正确性检验

- 导数的定义

$$loss = f(Y_{(n,m)})$$

$$Y_{(n,m)} = X_{(n,f)} W_{(f,m)}$$

$$\left\{ \frac{dloss}{dX} \right\}_{(n,f)} = \left\{ \frac{dloss}{dY} \right\}_{(n,m)} * W_{(m,f)}^T$$

$$\left\{ \frac{dloss}{dW} \right\}_{(f,m)} = X_{(f,n)}^T \left\{ \frac{dloss}{dY} \right\}_{(n,m)}$$

$$f'(x_0) = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0} [1]:154$$


$$\left\{ \frac{dloss}{dZ} \right\}_{(n,f)} = softmax(Z_{(n,f)}) - Y_{(n,f)}$$

$$\left\{ \frac{dloss}{dW^1} \right\}_{(h,f)} = \tilde{H}_{(h,n)}^T * (softmax(Z_{(n,f)}) - Y_{(n,f)})$$

$$\left\{ \frac{dloss}{dW^0} \right\}_{(c,h)} = \tilde{X}_{(c,n)}^T * ((softmax(Z_{(n,f)}) - Y_{(n,f)}) * (W^1)_{(f,h)}^T)$$



## 2. 算法实现——后向传播（矩阵角度）



Basic  
矩阵求导

梯度

梯度更新

$$loss = f(Y_{(n,m)})$$

$$Y_{(n,m)} = X_{(n,f)} W_{(f,m)}$$

$$\left\{ \frac{dloss}{dX} \right\}_{(n,f)} = \left\{ \frac{dloss}{dY} \right\}_{(n,m)} * W_{(m,f)}^T$$

$$\left\{ \frac{dloss}{dW} \right\}_{(f,m)} = X_{(f,n)}^T \left\{ \frac{dloss}{dY} \right\}_{(n,m)}$$

$$\left\{ \frac{dloss}{dZ} \right\}_{(n,f)} = softmax(Z_{(n,f)}) - Y_{(n,f)}$$

$$\left\{ \frac{dloss}{dW^1} \right\}_{(h,f)} = \tilde{H}_{(h,n)}^T * (softmax(Z_{(n,f)}) - Y_{(n,f)})$$

$$\left\{ \frac{dloss}{dW^0} \right\}_{(c,h)} = \tilde{X}_{(c,n)}^T * ((softmax(Z_{(n,f)}) - Y_{(n,f)}) * (W^1)_{(f,h)}^T)$$

$$W^1 = W^1 - \eta \frac{dloss}{dW^1}$$

$$W^0 = W^0 - \eta \frac{dloss}{dW^0}$$





### 2. 算法实现——其他

- 基于Numpy重写
  - 优化器Adam
  - 权重矩阵初始化
  - Weight Decay损失
- 结果（未考虑dropout）
  - 因为Numpy数据保存的是float64, Tensorflow是float32, 所以复现时取得了略好的结果

| 数据集      | Paper   | Local   |
|----------|---------|---------|
| Cora     | 0.80999 | 0.81000 |
| Citeseer | 0.70899 | 0.71100 |
| Pubmed   | 0.79400 | 0.79399 |


### 3. 进一步思考

- 通过对论文的复现，发现图神经网络都基于以下的模式
  - 在图上进行多步传播信息，反映在隐藏层的个数的设置上
  - 每步做两个操作
    - $T^{t-1} = A H^{t-1}$ : 基于图结构的信息，用来自邻居节点的信息更新自己
    - $H^t = T^{t-1} W$ : 对每个节点进行一系列复杂的操作
  - 对于GGNNs<sup>[1]</sup>，该论文属于Graph Convolution Network中Spatial Based的方法
    - A: 右上图, 来自论文<sup>[1]</sup>
    - W: 图片来源<sup>[2]</sup>



|   | Outgoing Edges |   |   |    | Incoming Edges |   |    |    |
|---|----------------|---|---|----|----------------|---|----|----|
|   | 1              | 2 | 3 | 4  | 1              | 2 | 3  | 4  |
| 1 |                | B |   |    |                |   |    |    |
| 2 |                |   |   |    |                |   |    |    |
| 3 |                |   | C | B' |                |   | C' |    |
| 4 |                |   |   |    |                |   |    | B' |

(c)  $A = [A^{(out)}, A^{(in)}]$



$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

[1]. Li Y, Tarlow D, Brockschmidt M, et al. Gated graph sequence neural networks[J]. arXiv preprint arXiv:1511.05493, 2015.

[2]. <https://www.yunaitong.cn/understanding-lstm-networks.html>

### 3. 进一步思考

- 通过对论文的复现和提取, 发现, 所谓的图神经网络都基于以下的模式

- 在图上进行多步传播信息
- 每步做两个操作
  - $T^{t-1} = AT^{t-1}$ : 基于图结构的信息, 来自邻居节点的信息更新自己
  - $H^t = T^{t-1}W$ : 对每个节点进行一系列复杂的操作
- 对于GGNNs<sup>[1]</sup>, 可概括为右图:

1. 初始化

$$H^{(0)} = [X_v, P]$$

$$A_v = [A_{in}, A_{out}]$$

2. 图操作

$$T^{(t-1)} = A_v(H^{(t-1)}W^A)$$

3. 节点操作

$$H^{(t)} =$$

$$\begin{aligned} & \delta(T^{(t-1)}W^{z_a}) \odot \tanh(T^{(t-1)}W^{h_a}) + \\ & \delta(T^{(t-1)}W^{z_a}) \odot \tanh\{\delta[(T^{(t-1)}W^{r_a} \odot H^{(t-1)})W^h]\} + \\ & \delta(T^{(t-1)}W^{z_a}) \odot \tanh\{\delta[(H^{(t-1)}W^r) \odot H^{(t-1)}] + H^{(t-1)}\} + \\ & \tanh(T^{(t-1)}W^{h_a}) \odot \delta(H^{(t-1)}W^{z_h}) + \\ & \tanh\{\delta[(T^{(t-1)}W^{r_a} \odot H^{(t-1)})W^h]\} \odot \delta(H^{(t-1)}W^{z_a}) + \\ & \delta(H^{(t-1)}W^{z_h}) \odot \tanh\{\delta[(H^{(t-1)}W^{r_h} \odot H^{(t-1)})W^h] - H^{(t-1)}\} + H^{(t-1)} \end{aligned}$$

[1]. Li Y, Tarlow D, Brockschmidt M, et al. Gated graph sequence neural networks[J]. arXiv preprint arXiv:1511.05493, 2015.

### 三、下一步工作

## ➤ 2019.08-2019.09 (已完成)

完成GNN调研，并阅读单机式并行化NeuGraph论文

## ➤ 2019.09-2019.10 (已完成)

完成Numpy复现Graph Convolution Neural Network中的Semi-GNN

## ➤ 2019.10-2019.11 (进行中)

阅读了Communication Neural Network,发现对于每个节点的邻居选择实际上不确定，放弃了该论文；现已阅读了Gated graph sequence neural network论文，正计划进行Numpy复现

## ➤ 2019.11-2020.3

实验NeuGraph论文中的代码，提出想法

谢 谢